

高光谱目标探测的进展与前沿问题

张良培¹

1 武汉大学测绘遥感信息工程国家重点实验室,湖北 武汉,430079

摘 要:针对高光谱目标探测问题的主要挑战,将高光谱目标探测的进展与前沿问题分为两个方面进行综述。基于信号检测理论的方法如结构化背景的约束能量最小化方法、非结构化背景的自适应一致性余弦评估器等,是高光谱目标的探测经典算法;随着统计模式识别与机器学习领域中新技术的出现,一些数据驱动的目标探测方法逐渐成为了高光谱目标探测的前沿问题,如核方法、稀疏表达方法等。概述了两类方法的特点,比较了各自的优势和不足,并展望了高光谱目标探测未来的发展趋势。

关键词:高光谱图像处理;目标探测;信号检测;机器学习

中图法分类号:P231.5; P237 **文献标志码:**A

高光谱遥感技术首次将图像空间特征与丰富的光谱特征结合,具有图谱合一、波段数目多和光谱连续等突出特点^[1],被列为遥感技术在 20 世纪后 20 a 三个最显著的进展之一^[2-5]。由于高光谱遥感图像可以提供区分不同物质的诊断性光谱特征信息,目标探测成为高光谱遥感图像处理中一个引人关注的重要问题。当目标的光谱特征已知时,探测算法需要将待探测的遥感图像中目标地物与其他地物进行区分,判断目标在各个像素内的存在性^[6];当目标和背景等先验信息未知时,则需要通过异常探测方法来获取目标的信息^[7-8]。本文主要聚焦于高光谱遥感图像的目标探测。近年来,高光谱图像目标探测技术已经在很多领域中得到成功应用,如矿物勘测、边境监察、搜索营救、军事侦察等,具有广阔的民用和军事应用前景。在学术界,各国学者也一直致力于高光谱目标探测新方法的研究:从 2009 年开始,历届 IEEE 高光谱图像与信号处理大会均安排有相关主题报告,并将目标探测作为专门分会场讨论;具有重要影响力的 IEEE 信号处理杂志在 2002 年和 2014 年的高光谱专刊中也分别有文献报道相关进展;罗切斯特理工学院提供的目标探测竞赛标准数据至今仍然活跃于 IEEE 遥感会刊的长文中。

高光谱目标探测与自然图像的目标跟踪或高分辨率遥感图像的目标识别的显著区别是:在高光谱目标探测中,由于地物分布情况复杂,传感器

空间分辨率限制,目标数目少尺寸小等原因,待探测目标通常以像素级甚至亚像素级的形式存在于图像中,例如在罗切斯特理工学院的探测图像中,车辆等目标完全无法通过目视判别。因此,像素的光谱特征是目标探测中唯一可以使用的输入特征;而在自然图像的目标跟踪或高分辨率遥感图像的目标识别中,由于图像的空间分辨率较高,目标占据较多的像素,此时更依赖于目标的形状、纹理等空间特征进行判别。高光谱图像目标探测问题的主要难点表现在以下两个方面^[9]:

1) 目标光谱变化问题。由于大气传输、传感器噪声、电磁波多次反射等因素的影响,高光谱遥感图像中目标的实地测量反射率光谱数据甚至实验室测量的反射率光谱数据都不是唯一确定的,而存在一定的变化性。同一种物质的不同像元,其光谱可能会呈现出一定的差异,这便是目标光谱的不确定性,即遥感图像中普遍存在的“同物异谱”现象。正是由于这种不确定性的存在,使得待测目标不能用唯一的光谱曲线进行描述,这为目标准确探测和识别带来了巨大困难。

2) 亚像元问题。由于空间分辨率的限制和地物分布的复杂性,高光谱遥感图像上很少有纯净像元存在。更多的情况是,目标地物占据像元的部分面积,与其他多种地物共同混合成一个像元。这时候,目标光谱作为一个端元,与其他背景端元共同组成混合像元的光谱,对应的目标探测

收稿日期:2014-09-04

项目来源:国家自然科学基金资助项目(41431175)。

第一作者:张良培,教授,主要研究方向为高光谱遥感、高分辨率遥感及遥感应用。E-mail:zlp62@whu.edu.cn

问题即亚像元目标探测问题。由于混合有多种背景端元,混合像元将呈现出多种端元的吸收特征,其光谱曲线整体形状也与目标端元有所差别。无论是基于吸收特征还是光谱形状整体匹配的方法,都会导致混合像元与目标端元光谱的匹配失败。

从模式分类的角度看来,高光谱目标探测的实质是一个二分类问题:将图像中的每一个像素分类为目标像素或背景像素。但是,不能简单地使用常规的分类器进行高光谱目标探测,主要原因是:① 高光谱目标探测中往往只知道单一目标的光谱,常规的分类算法难以仅仅利用单一或少量的训练样本构建分类器;② 高光谱目标探测中目标像素的数量在图像中所占比例极少,甚至只存在于几个像素中,而图像中绝大多数像素都是背景像素。常规分类方法都是以整体分类精度最小化为目标函数,往往会导致将图像中全部像素错分为背景错误^[5]。实际上,在目标探测中,常常以保持一定的错误探测(虚警率)的情况下,探测率达到最大为最优的准则^[10]。

本文将分两个部分分别介绍高光谱目标探测的经典算法和最新发展趋势。从上世纪90年代起,有一系列的研究将信号检测的理论与方法引入到高光谱图像处理中^[11],并针对高光谱数据特点建立了较为完善的目标探测器设计框架^[12],本文分别从结构化背景及非结构化背景两个方面进行综述;随着统计模式识别与机器学习领域中新算法不断涌现,一些数据驱动的目标探测方法逐渐成为了高光谱目标探测的前沿问题,如核方法^[13]、稀疏表达方法^[14]、流形学习方法^[15]、迁移学习方法^[16]、背景自学习方法^[17]、正则化方法^[18]等等。最后,给出了若干讨论与展望。

1 高光谱目标探测的经典方法

高光谱遥感图像目标探测的经典方法的一般流程是:将图像数据点的光谱特征按照一定的准则(即探测器)投影到某一平面上,保证在这个探测结果的平面上目标与背景分别位于不同的位置,然后通过阈值分割的方法将目标从背景中分离出来,如图1所示。在高光谱目标探测过程中,描述背景的模型不同导致了高光谱目标探测方法的分类不同。基于此,本文将高光谱遥感图像目标探测的经典方法分为结构化背景和非结构化背景两方面进行综述。除此以外,也有少量结合了两者的混合探测器的研究,并发展出了混合

结构化探测器和混合非结构化探测器^[19-20]。




图1 高光谱目标探测的一般流程

Fig. 1 General Schedule of Hyperspectral Target Detection

1.1 结构化背景探测器

结构化背景的目标探测方法描述图像中像元光谱变化的数学模型有三种:概率密度模型、子空间模型和线性光谱混合模型,其中最经典的是以线性混合模型为基础的方法^[21]。典型方法有基于有限冲积响应滤波器的约束能量最小化方法(constrained energy minimization, CEM)的方法^[22],以及将像元信号投影到与各个背景端元正交方向的正交子空间目标探测方法(orthogonal subspace projection, OSP)^[23]等。以上两种方法都有若干改进算法,如在CEM算法基础上的干扰子空间投影方法(ISP)^[24]、信号分解/背景抑制的目标探测器(SDIA)^[25]、线性约束最小方差检测算法(LCMV)^[26]、目标约束干扰最小滤波器方法(target-constrained interference minimized filter, TCIMF)^[27]等,以及在OSP算法基础上的后验的OSP方法^[28]、斜交子空间投影(OBP)算法^[29]、恒虚警率子空间投影算法^[30]等。其中几种重要的方法包括CEM、TCIMF以及OSP。

1) 约束能量最小化方法(CEM)^[22]。CEM技术来源于数字信号处理中的线性约束最小方差波束形成器。该方法是在仅知道感兴趣目标的光谱,而对背景一无所知的条件下,对目标进行探测的方法,其思想是提取特定方向的信号而压抑其他方向的信号。记 $S = \{r_1, r_2, \dots, r_N\}$ 为所有像素集合,其中 $r_i = (r_{i1}, r_{i2}, \dots, r_{iL})^T$ 为任意样本像元光谱向量。CEM的目的就是设计一个FIR线性滤波器 $w = (w_1, w_2, \dots, w_L)^T$ 使得在条件(1)下滤波输出能量最小。假设 d 是所感兴趣的的目标光谱,滤波器 w 可通过最小值问题(1)优化:

$$\min_w \left(\sum_{i=1}^N y_i^2 / N \right) = \min_w (w^T R w),$$

$$\text{s. t. } d^T w = 1 \quad (1)$$

式(1)的解为:

$$w^* = R^{-1}d / (d^T R d) \quad (2)$$

式中, $R = (\sum_{i=1}^N r_i r_i^T) / N$ 为样本集合 S 的自相关矩阵。将 CEM 算子(式(2))作用于图像中的每个像元,即得到目标在图像中的分布概率图像,实现目标探测。

2) 目标约束下的干扰最小化滤波算法(TCIMF)^[27]。背景和噪声的干扰在对目标探测有着至关重要的影响。假设一幅图像的像元由三部分信号源组成: D (期望的目标信号), U (不期望的目标信号)和 I (干扰),TCIMF 算法同时约束 D 和 U ,在 D 的期望目标特征被探测出来的同时 U 中不期望目标特征被消除。 $D = [d_1, \dots, d_p]$ 和 $U = [u_1, \dots, u_q]$ 分别代表期望的目标光谱和非期望的目标光谱矩阵,TCIMF 的目标函数是以下线性约束最优问题:

$$\min_w (w^T R w), \quad \text{s. t. } [D, U]^T w = \begin{bmatrix} I_{P \times 1} \\ 0_{Q \times 1} \end{bmatrix} \quad (3)$$

式中, R 为样本自相关矩阵; $I_{P \times 1}$ 为全是 1 的 P 维列向量,用来约束 D 中的期望目标特征; $0_{Q \times 1}$ 为全是 0 的 Q 维列向量,用来消除 U 中的不期望目标特征。解得最优权重矩阵 w :

$$w = R_{L \times L}^{-1} [DU] ([DU]^T R_{L \times L}^{-1} [DU])^{-1} \begin{bmatrix} I_{P \times 1} \\ 0_{Q \times 1} \end{bmatrix} \quad (4)$$

由此得到 TCIMF 的探测算子 $D = w^T x$ 。

3) 正交子空间投影方法(OSP)^[23]。OSP 是在同时知道感兴趣目标光谱和不感兴趣的背景光谱的前提下,一种非常好的目标探测算子。在结构化背景的探测理论中,线性混合光谱模型中的端元光谱矩阵可以进一步分解为感兴趣的目标端元和不感兴趣的背景端元,后者是由非目标的各类背景端元组成矩阵。背景像元在图像中的数量相对于目标像元占主导地位。像元可以描述为:

$$r = d\alpha_p + U\gamma + n \quad (5)$$

式中, $U = (u_1, \dots, u_{p-1})$ 为不感兴趣的背景端元矩阵; γ 为背景端元的丰度矩阵。OSP 方法将数据投影到 U 的正交补矩阵空间 $P = I - UU^\# = I - U(U^T U)^{-1} U^T$, P 将 U 分量消除,从而抑制了图像中不感兴趣目标的特征分量:

$$Pr = Pd\alpha_p + Pn \quad (6)$$

再利用最大化信噪比的原则最终得到 OSP 探测算子:

$$D = d^T Pr \quad (7)$$

OSP 算法与 CEM 算法是紧密相连的^[25], 即:

$$w_{\text{CEM}} = (d^T R_r^{-1} d)^{-1} R_r^{-1} d = (d^T R_m^{-1} d)^{-1} R_m^{-1} d \approx (d^T P_U^\perp d)^{-1} P_U^\perp d = P_{\text{OSP}} \quad (8)$$

一般来说,CEM 的探测效果会略优于 OSP 的探测效果,这是由于 CEM 消除了无法识别是目标还是背景的信号源并且抑制了噪声,但 CEM 的劣势在于对于感兴趣目标的光谱要求非常苛刻,因为具有与先验目标光谱轻微差别的像元可能就会被判别为非目标。

OSP 算法与 TCIMF 算法也是有紧密联系的^[31]:

$$w_{\text{TCIMF}}^T r_i = \frac{g^T y_i}{g^T g} = \frac{h^T P_S^\perp y_i}{h^T P_S^\perp h} \quad (9)$$

式中, g 是白化目标光谱的投影。式(9)表明 TCIMF 等价于目标、干扰和接受到的信号全部被白化后的 OSP 算法。

1.2 非结构化背景探测器

与结构化背景不同,非结构化背景探测器不用端元信号加对应组分的这种结构化模型来表达背景信息,而是将背景视为符合多元高斯分布的统计模型,将背景、噪声统一视为背景进行建模。例如,基于广义似然比的探测方法(generalized likelihood ratio test, GLRT)^[32]、自适应余弦一致性评估器(adaptive coherence/cosine estimator, ACE)^[33]、自适应匹配滤波器(adaptive matched filter, AMF)^[10]、自适应子空间探测器(ASD)^[32]、匹配子空间探测器(MSD)^[34]、目标信号子空间匹配方法^[34]等。在文献[5]中,为克服目标探测中的光谱变化现象,Manolakis 等利用子空间匹配滤波器总结了多种针对高光谱遥感图像非结构化的目标探测算法。其中几种重要的方法包括 GLRT、ACE 以及 AMF。

1) 基于广义似然比的探测方法(GLRT)^[35]。假设背景是一个混合模型,即假设加性噪声已经包含在背景中,背景 b 服从多元正态分布 $b \sim N(\mu_0, \Gamma)$,将均值 μ_0 从观测值 x 中移去后,完整的假设为:

$$H_0: x = b, H_1: x = Sa + b \quad (10)$$

式中, H_0 为目标不存在的情况; H_1 为目标存在的情况,分布分别为 $x \sim N(0, \Gamma)$ 和 $x \sim N(Sa, \Gamma)$ 。GLRT 探测算法为:

$$D_K(x) = \frac{x^T \Gamma^{-1} S(S^T \Gamma^{-1} S)^{-1} S^T \Gamma^{-1} x}{N + x^T \Gamma^{-1} x} \stackrel{H_1}{>} \stackrel{H_0}{<} \eta_k \quad (11)$$

式中, N 为用来估计背景的样本 x_n 像元总数; $\Gamma = \sum_N x_n x_n^T / N$ 。通过 GLRT, 可以推导出很多实用的探测算法, 并可广泛应用于高光谱图像的目标探测中。

2) 自适应一致性余弦评估器 (ACE)^[33] 是 GLRT 的一种自适应版本。GLRT 中一个关键性假设是在 H_0 和 H_1 两种假设地物中背景协方差矩阵相同。然而, 对于亚像元目标, 在两种假设中的背景覆盖区域数量是不相同的。因此, 使用如下的假设更加适用:

$$H_0: x = b, H_1: x = Sa + \sigma b \quad (12)$$

式中, H_0 和 H_1 的分布分别为 $x \sim N(0, \Gamma)$ 和 $x \sim N(Sa, \sigma^2 \Gamma)$ 。即背景在两种假设下有着相同的协方差结构, 但有着不同的方差。该方差直接关系到目标填充因子, 也就是目标物体占据像元区域的比例。根据 ACE 算法的背景模型, 式(11)改写为:

$$D_{ACE}(x) = \frac{x^T \Gamma^{-1} S (S^T \Gamma^{-1} S)^{-1} S^T \Gamma^{-1} x}{x^T \Gamma^{-1} x} \stackrel{H_1}{>} \stackrel{H_0}{<} \eta_{ACE} \quad (13)$$

式(13)与式(11)相比, 只需在分母中去掉背景训练样本的数目 N 。

3) 自适应匹配滤波器 (AMF)^[10] 是 GLRT 的另一种自适应版本。当不考虑目标光谱变化的情况下, 即目标子空间的维数为 1, 可以由单一向量 s 确定, 于是式(11)可以简化成:

$$D_{AMFE}(x) = \frac{(S^T \Gamma^{-1} S)^2}{(S^T \Gamma^{-1} S)(N + (S^T \Gamma^{-1} S))} \stackrel{H_1}{>} \stackrel{H_0}{<} \eta_{AMF} \quad (14)$$

需要注意的是, 以上公式中的 Γ 如果使用高光谱图像自相关矩阵 R 代替, 则公式形式不变; 如果用高光谱图像协方差矩阵, 则光谱向量 x 和目标向量 s 需要减去背景均值 μ_0 。

当目标子空间的维数为 1 时, 式(11)可以写成更一般的形式:

$$D(x) = \frac{(S^T \Gamma^{-1} S)^2}{(S^T \Gamma^{-1} S)(\Psi_1 + \Psi_2 x^T \Gamma^{-1} x)} \stackrel{H_1}{>} \stackrel{H_0}{<} \eta \quad (15)$$

当 $\Psi_1 = N, \Psi_2 = 1$ 时, 式(15)即为 GLRT; 当 $\Psi_1 = 0, \Psi_2 = 1$ 时, 式(15)即为 ACE 探测算法; 当 $\Psi_1 = N, \Psi_2 = 0$ 时, 式(15)即为 AMF 探测算法。

2 高光谱目标探测的新技术

由于高光谱图像的复杂性, 上述高光谱目标探测的经典方法往往依赖于一些特定的统计假设, 因

此仅在符合条件的情况下取得较好的目标探测结果。例如, 基于信号检测的自适应匹配滤波器算法假设目标与背景具有相同的方差矩阵, 但是该假设在一些实际情况中并不能成立^[36]。近年来, 在高光谱遥感图像目标探测领域中出现了一些模式识别与机器学习的新方法, 最新研究表明, 这些方法能够取得非常好的目标探测效果, 并且在很多情况下具有优势。结合本领域最新文献及本研究组的相关成果, 本文主要介绍以下方面的内容。

2.1 核方法

为解决线性混合模型探测方法的不足, 近年来许多学者将核方法引入到传统线性目标探测方法中。核函数提供了一种在适当的特征空间中用常规的线性算法检测非线性关系的方法, 利用基于核函数映射方法将在低维特征空间中不可分的数据集通过核策略映射到更高维的空间中, 使得目标和背景可以更好地被区分, 如 KOSP^[37], KCEM^[38], KMSD^[39], KTCIMF^[40]等方法。

如果定义输入的高光谱数据集为 X , 核方法定义的非线性特征映射 Φ , 核映射的目的是寻找一个合适的映射函数 Φ , 把原始数据集的 X 映射到更高维的特征空间 F , 使得原始空间中的非线性问题转化为特征空间中的线性问题。由于映射后的特征空间的维数可能非常大, 在特征空间中直接求解某一表达式的难度很大, 为了避免显性地计算映射函数 $\Phi(x_i)$, 可以把特征空间中的两个高维向量的内积作为输入特征的直接函数。一般将特征空间中的两个高维向量的表示直接计算向量内积的函数称为核函数, 即:

$$k(x_i, x_j) = \langle \Phi(x_i), \Phi(x_j) \rangle = \Phi(x_i) \cdot \Phi(x_j) \quad (16)$$

通过这样的方式, 使得核函数 $k(x_i, x_j)$ 在特征空间 F 中可以被隐式地表达, 避免在高维空间中直接计算两个高维向量的点积, 使计算可行。具有上述性质的函数即核函数, 包括高斯径向基核函数 (RBF)、多项式核函数、反曲核函数等等^[41]。在众多的 Mercer 核函数中, 一般选择高斯 RBF 核函数进行实验设计。这是由于它是具有平移不变性的核函数, 只由输入向量之间的差别决定, 而与其中每个光谱向量的偏移无关, 因此, 可以克服高光谱数据中不均匀光照等原因给光谱特征带来的影响。高斯核函数的表达形式如式(17):

$$k(x_i, x_j) = \exp(-(\|x_i - x_j\|^2 / c)) \quad (17)$$

式中, c 是一个正的常数, 是高斯 RBF 核函数的参数。

2.2 稀疏表达模型

基于稀疏表达模型的目标探测器^[14, 42]中,假设目标测试样本和背景测试样本可以分别由一系列的目标训练样本和背景训练样本线性表示,则

$$\begin{aligned} x &\approx (\alpha_1^b a_1^b + \alpha_2^b a_2^b + \cdots + \alpha_{N_b}^b a_{N_b}^b) + (\alpha_1^t a_1^t + \alpha_2^t a_2^t + \cdots + \alpha_{N_t}^t a_{N_t}^t) \\ &= \underbrace{[a_1^b \ a_2^b \ \cdots \ a_{N_b}^b]}_{A^b} \underbrace{[\alpha_1^b \ \alpha_2^b \ \cdots \ \alpha_{N_b}^b]}_{\alpha^b} + \underbrace{[a_1^t \ a_2^t \ \cdots \ a_{N_t}^t]}_{A^t} \underbrace{[\alpha_1^t \ \alpha_2^t \ \cdots \ \alpha_{N_t}^t]}_{\alpha^t} \\ &= A^b \alpha^b + A^t \alpha^t = A \alpha \end{aligned} \quad (18)$$

式中, $\{a_i^b\}_{i=1,2,\dots,N_b}$ 、 $\{a_i^t\}_{i=1,2,\dots,N_t}$ 分别表示 N_b 个背景训练样本和 N_t 个目标训练样本; $A = [A^b \ A^t]$ 是目标和背景联合字典; α^b 和 α^t 是对应的系数, α 是稀疏向量。

给定字典 A 时,稀疏向量 α 可以通过求解下面的优化问题得到:

$$\hat{\alpha} = \arg \min \|\alpha\|_0 \text{ subject to } \|A\alpha - x\|_2 \leq \varepsilon_0 \quad (19)$$

式中, $\|\cdot\|_0$ 代表 l_0 -norm, 即向量 α 中的非零元个数。上述优化问题可以由任意的贪婪追踪算法求解, 而且该优化问题是 NP 难的, 可以用能够被标准凸优化技术求解的 l_1 -norm $\|\alpha\|_1 = \sum_{i=1}^N |\alpha_i|$ 替代。

求解得到的稀疏系数 $\hat{\alpha}$ 分解成 $\hat{\alpha}^b$ 和 $\hat{\alpha}^t$, 然后利用背景训练样本和目标训练样本分别结合其对应的系数对待测试样本进行重建, 可以获得重建残差如下:

$$r_b(x) = \|x - A^b \hat{\alpha}^b\|, r_t(x) = \|x - A^t \hat{\alpha}^t\| \quad (20)$$

每种类别下重建残差越小, 该像素越有可能属于该类, 因此可以利用两种类别下的残差之差作为该测试样本的探测统计值。

$$D(x) = r_b(x) - r_t(x) \quad (21)$$

根据该探测统计值与特定阈值的大小关系来判定该像素属于背景类还是目标类, 如果探测统计值大于该阈值, 则为目标类, 反之为背景类。

值得注意的是, 上述稀疏探测器的思想是将目标探测看作一个二分类的问题, 利用稀疏表达分类器^[43]的思想来处理目标探测问题。但是由于高光谱图像上目标类像素数量很少, 分类器并不一定适用于目标探测, 文献^[44]考虑亚像元目标的组成结构, 提出基于传统的二元假设的稀疏模型, 针对背景和背景类分别建立过完备的字典。

2.3 判别子空间分析

基于判别子空间分析的高光谱图像目标探测方法是根据已有的训练样本特征, 设计某种目标

对于高光谱图像中任意的未知样本, 都可以由目标和背景测试样本组成的过完备字典表达, 同时假设系数向量中只包含有少量的非零元, 如式(18)所示。

函数, 找到数据集所在原始特征空间对应的判别特征子空间, 使得目标样本与背景样本在该子空间中的分离度更大, 以提高目标探测的精度。具体原理可以表示为:

$$y = F(x) \quad (22)$$

式中, $x \in R^L$ 和 $y \in R^d$ 分别表示样本在原始光谱特征空间和特征判别子空间中的特征向量。如果特征变换是线性投影, 则公式可进一步表示为 $y = W^T x$, 其中 W 为投影矩阵, 例如基于稀疏迁移流形嵌入的方法^[16]、动态子空间投影^[45]等。在新的判别特征子空间中, 可以使用最小距离法得到每个测试样本与目标(正样本)的距离, 进而获得目标探测结果概率图像; 也可以在新的特征空间中直接使用经典的目标探测方法(如 ACE 等)得到目标探测结果。

此外, 基于测度学习的目标探测方法可以视为特征子空间分析方法。一般地, 在机器学习方法中, 任意两个样本 x_i 和 x_j 之间的相似程度可以通过其在特征空间中的欧氏距离描述:

$$d(x_i, x_j) = \sqrt{(x_i - x_j)^T (x_i - x_j)} \quad (23)$$

在目标探测中, 为了尽可能地突出训练样本集中目标-目标样本对的相似性同时抑制目标-背景样本对的不相似性, 可以通过目标函数找到新的低秩距离测度矩阵 $M \in R^{L \times L}$, 并用它作为距离测度计算的依据:

$$\begin{aligned} d(x_i, x_j) &= \sqrt{(x_i - x_j)^T M (x_i - x_j)} = \\ &= \sqrt{(x_i - x_j)^T W W^T (x_i - x_j)} = \|W^T x_i - W^T x_j\| \end{aligned} \quad (24)$$

由式(24)可知, 通过矩阵 M 的测度学习等效于利用矩阵 W 对原始数据进行特征子空间分析。

值得注意的是, 在设计算法找到投影矩阵 W 或距离测度矩阵 M 的过程中, 必须充分考虑高光谱图像的特点、先验信息的情况等, 以找到最合适的特征子空间。如文献^[46]中探索了样本集分布的判别性局部结构, 文献^[16]中考虑了训练样本与测试样本的不同域问题和原始光谱特征维数高的问题, 而文献^[47]则专门考虑了亚像元目标在

混合像元中的贡献。

2.4 光谱数据自学习

在高光谱目标探测任务中,地物端元的光谱特征由于大气影响、环境因素、地物表面干扰、地物材料不均匀以及光线变化等因素干扰,会发生变化,从而影响目标探测效果。因此,对于目标先验的光谱变化现象及其对探测结果的影响展开研究,是非常有意义也非常有必要的。相关最新研究表明,利用高光谱图像自身,通过数据点云之间的互相学习、自发学习的方式,能够获得稳定且有效的目标和背景先验生成方法。

迭代自适应定权的最优目标先验生成方法是随机选择目标光谱特征被作为训练样本输入目标探测器(如 ACE),得到一个探测结果图,每个像素都会得到一个分值 $[\delta_0(x_1), \dots, \delta_0(x_N)]$,用这个分值当作权值来调整目标先验^[48]:

$$x_{T_1} = \sum_{i=1}^N (\delta_0(x_i) \cdot x_i) \quad (25)$$

调整后计算光谱信息散度 $T_s = \text{SID}(x_{T_1}, x_{T_0})$ 判断是否与之前的目标先验非常相似,几乎没有变化。当计算出 T_s 大于 η 时,则将 x_{T_1} 作为目标先验迭代完成上述步骤,直到 T_s 不大于 η 时停止,此时认定迭代结果收敛,生成了最优的目标先验。

稀疏约束的目标先验生成方法从高光谱数据自身出发,建立关于目标地物光谱特征的过完备字典,从图像上选择能够表征目标光谱特征各种存在形式的原子。如果随机选择了一个目标像元作为先验目标光谱,那么利用这条光谱得到的探测结果中,得分值较大位置上的原始像元应作为构建此目标过完备字典的原子。根据原始光谱和 ACE 的探测结果选择探测值较大的部分位置自适应构建目标字典后,采用正交匹配追踪(orthogonal matching pursuit, OMP)稀疏求解方法求解稀疏系数,即原子的位置^[49]。得到了对目标地物影响较大的原子位置后,进行平均生成该方法的最优目标先验。

高光谱遥感数据背景自学习方法则试图克服基于全局背景估计和局部背景估计的方法不能最佳地估计背景信息的弱点,考虑使用不同种类地物建立一个多元正态分布的集合^[17]。该框架分为 5 个步骤:估计图像端元数,背景数据聚类融合,含有目标聚类的去除,待测试样本的不同标签方法和结合空间和光谱信息的标签决策策略。通过自适应背景信息参数代替固定的背景信息参数,使得传统的非结构化探测器具有更准确的背

景信号抑制能力。

3 讨论与展望

是否存在一种最好的高光谱目标探测算法是高光谱目标探测领域的权威专家 Manolakis 教授在他的一篇论文里提出的问题^[50],也是多年来遥感图像处理的学者们试图回答的问题。事实上,针对本文指出的高光谱目标探测问题的两大挑战,经典的基于信号处理的高光谱目标探测算法(例如大量研究论文的实验部分被用来作为对比实验的 AMF、CEM、OSP 等)已经被证明是非常有效的高光谱目标探测算法。但是,这些算法往往都建立在特定的模型基础之上,如果模型不符合真实数据,上述这些算法就不能输出令人满意的目标探测结果。

本文结合信号处理、模式识别与机器学习的新方法,从与经典方法截然不同的角度总结了几类高光谱目标探测新技术:核方法、稀疏表达模型、判别子空间分析和光谱数据自学习方法等,这些方法代表了高光谱目标探测的重要前沿方向。然而,机器学习方法用于高光谱目标探测仍然有诸多需要完善的问题,例如:① 机器学习方法中模型的建立往往需要一定数量的可靠训练样本,而这一点在高光谱目标探测中常常得不到满足,因为高光谱目标探测问题的先验知识只有单一的目标光谱,因此需要发展对训练样本的分析与自动生成方法。② 机器学习方法中往往有许多参数需要确定,而在高光谱目标探测中没有足够的数据用于多参数的交叉验证,因此需要探索模型参数的自适应确定规则。③ 机器学习方法的计算复杂度随着问题规模的扩大往往急剧增大,而高光谱目标探测中的样本集常常达到百万像素,因此学习模型的近似优化也是一个值得关注的重要问题。

尽管近年来出现的文献表明机器学习方法能够取得非常好的目标探测效果,但是总体看来,现有的实验结果并不能证明基于机器学习的方法超越了经典的信号检测方法。事实上,我们需要验证是否在不同场景、成像条件、目标类别的大量数量的目标探测实验才能绘制出理想的 ROC 曲线。即使从现有的实验结果来看,在某些数据实验中两类方法的差异并不显著。作者认为,信号检测方法和机器学习方法是两类非常有效的高光谱目标探测方法,它们各自都有其优势和不足,并且将一直是高光谱目标探测的重要研究方向。

参 考 文 献

- [1] Zhang Liangpei, Du Bo, Zhang Lefei. Processing of Hyperspectral Remote Sensing Image[M]. Beijing: Science Press, 2014(张良培, 杜博, 张乐飞. 高光谱遥感影像处理[M]. 北京: 科学出版社, 2014)
- [2] Goetz A F H, Vane G, Solomon J E, et al. Imaging Spectrometry for Earth Remote Sensing [J]. *Science*, 1985, 228(4 704): 1 147-1 153
- [3] Bioucas-Dias J, Plaza A, Camps-Valls G, et al. Hyperspectral Remote Sensing Data Analysis and Future Challenges[J]. *IEEE Geosci. Remote Sens. Mag.*, 2013, 1(2): 6-36
- [4] Tong Q, Xue Y, Zhang L. Progress in Hyperspectral Remote Sensing Science and Technology in China over the Past Three Decades[J]. *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, 2014, 7(1): 70-91
- [5] Manolakis D, Shaw G. Detection Algorithms for Hyperspectral Imaging Applications [J]. *IEEE Signal Process. Mag.*, 2002, 19(1): 29-43
- [6] Du Bo. Study on Small Object Detection in Hyperspectral Remote Sensing Images[D]. Wuhan: Wuhan University, 2009(杜博. 高光谱遥感影像亚像元小目标探测研究[D]. 武汉: 武汉大学, 2009)
- [7] Stein D W G, Beaven S G, Hoff L E, et al. Anomaly Detection from Hyperspectral Imagery [J]. *IEEE Signal Process. Mag.*, 2002, 19(1): 58-69
- [8] Matteoli S, Diani M, Corsini G. A Tutorial Overview of Anomaly Detection in Hyperspectral Images [J]. *IEEE Aerosp. Electron. Syst. Mag.*, 2010, 25(7): 5-28
- [9] Manolakis D, Truslow E, Pieper M, et al. Detection Algorithms in Hyperspectral Imaging Systems: An Overview of Practical Algorithms [J]. *IEEE Signal Process. Mag.*, 2014, 31(1): 24-33
- [10] Robey F C, Fuhrmann D R, Kelly E J, et al. A CFAR Adaptive Matched Filter Detector[J]. *IEEE Trans. Aerosp. Electron. Syst.*, 1992, 28(1): 208-216
- [11] Yu X, Reed I S, Stocker A D. Comparative Performance Analysis of Adaptive Multispectral Detectors[J]. *IEEE Trans. Signal Process.*, 1993, 41(8): 2 639-2 656
- [12] Manolakis M, Marden D, Shaw G A. Hyperspectral Image Processing for Automatic Target Detection Applications[J]. *Lincoln Lab. J.*, 2003, 14(1): 79-116
- [13] Kwon H, Nasrabadi N M. Kernel Spectral Matched Filter for Hyperspectral Imagery[J]. *Int. J. Comput. Vision*, 2007, 71(2): 127-141
- [14] Chen Y, Nasrabadi N M, Tran T D. Sparse Representation for Target Detection in Hyperspectral Imagery[J]. *IEEE J. Sel. Top. Signal Process.*, 2011, 5(3): 629-640
- [15] Ma L, Crawford M M, Tian J. Anomaly Detection for Hyperspectral Images Based on Robust Locally Linear Embedding[J]. *J. Infrared Milli. Terahz. Waves*, 2010, 31(6): 753-762
- [16] Zhang L, Zhang L, Tao D, et al. Sparse Transfer Manifold Embedding for Hyperspectral Target Detection[J]. *IEEE Trans. Geosci. Remote Sens.*, 2014, 52(2): 1 030-1 043
- [17] Wang T, Du B, Zhang L. A Background Self-learning Framework for Unstructured Target Detectors [J]. *IEEE Geosci. Remote Sens. Lett.*, 2013, 10(6): 1 577-1 581
- [18] Zhang Y, Du B, Zhang L. Regularization Framework for Target Detection in Hyperspectral Imagery [J]. *IEEE Geosci. Remote Sens. Lett.*, 2014, 11(1): 313-317
- [19] Broadwater J, Chellappa R. Hybrid Detectors for Subpixel Targets[J]. *IEEE Trans. Pattern Anal. Mach. Intell.*, 2007, 29(11): 1 891-1 903
- [20] Zhang L, Du B, Zhong Y. Hybrid Detectors Based on Selective Endmembers[J]. *IEEE Trans. Geosci. Remote Sens.*, 2010, 48(6): 2 633-2 646
- [21] Manolakis D, Siracusa G, Shaw G. Hyperspectral Subpixel Target Detection Using the Linear Mixing Model[J]. *IEEE Trans. Geosci. Remote Sens.*, 2001, 39(7): 1 392-1 409
- [22] Harsanyi J C. Detection and Classification of Subpixel Spectral Signatures in Hyperspectral Image Sequences[D]. Baltimore: University of Maryland Baltimore County, 1993
- [23] Harsanyi J C, Chang C I. Hyperspectral Image Classification and Dimensionality Reduction: An Orthogonal Subspace Projection Approach [J]. *IEEE Trans. Geosci. Remote Sens.*, 1994, 32(4): 779-785
- [24] Tu T M, Chen C H, Chang C I. A Noise Subspace Projection Approach to Target Signature Detection and Extraction in an Unknown Background for Hyperspectral Images[J]. *IEEE Trans. Geosci. Remote Sens.*, 1998, 36(1): 171-181
- [25] Du Q, Chang C I. A Signal-decomposed and Interference-annihilated Approach to Hyperspectral Target Detection[J]. *IEEE Trans. Geosci. Remote Sens.*, 2004, 42(4): 892-906
- [26] Chang C I, Ren H, Chiang S S. Real-time Processing Algorithms for Target Detection and Classification.

- tion in Hyperspectral Imagery[J]. *IEEE Trans. Geosci. Remote Sens.*, 2001, 39(4): 760-768
- [27] Ren H, Chang C I. Target-constrained Interference-minimized Approach to Subpixel Target Detection for Hyperspectral Images[J]. *Opt. Eng.*, 2000, 39(12): 3 138-3 145
- [28] Tu T M, Chen C H, Chang C I. A Posteriori Least Squares Orthogonal Subspace Projection Approach to Desired Signature Extraction and Detection[J]. *IEEE Trans. Geosci. Remote Sens.*, 1997, 35(1): 127-139
- [29] Behrens R T, Scharf L L. Signal Processing Applications of Oblique Projection Operators[J]. *IEEE Trans. Signal Process.*, 1994, 42(6): 1 413-1 424
- [30] He Lin, Pan Quan, Zhao Yongqiang. CFAR Target Detection in Unknown Background Based on Subspace Projection in Aerial Hyperspectral Imagery[J]. *Acta Aeronautica et Astronautica Sinica*, 2006, 27(4): 657-662(贺霖, 潘泉, 赵永强, 等. 基于子空间投影的未知背景航拍高光谱图像恒虚警率目标检测[J]. *航空学报*, 2006, 27(4): 657-662)
- [31] Johnson S. Constrained Energy Minimization and the Target-constrained Interference-Minimized Filter[J]. *Opt. Eng.*, 2003, 42(6): 1 850-1 854
- [32] Kraut S, Scharf L L, McWhorter L T. Adaptive Subspace Detectors [J]. *IEEE Trans. Signal Process.*, 2001, 49(1): 1-16
- [33] Kraut S, Scharf L L. The CFAR Adaptive Subspace Detector is a Scale-Invariant GLRT [J]. *IEEE Trans. Signal Process.*, 1999, 47(9): 2 538-2 541
- [34] Shaw G, Manolakis D. Signal Processing for Hyperspectral Image Exploitation [J]. *IEEE Signal Process. Mag.*, 2002, 19(1): 12-16
- [35] Kelly E J. An Adaptive Detection Algorithm[J]. *IEEE Trans. Aerosp. Electron. Syst.*, 1986, 2 (2): 115-127
- [36] Sakla W, Chan A, Ji J, et al. An SVDD-Based Algorithm for Target Detection in Hyperspectral Imagery[J]. *IEEE Geosci. Remote Sens. Lett.*, 2011, 8(2): 384-388
- [37] Capobianco L, Garzelli A, Camps-Valls G. Target Detection with Semisupervised Kernel Orthogonal Subspace Projection[J]. *IEEE Trans. Geosci. Remote Sens.*, 2009, 47(11): 3 822-3 833
- [38] Jiao X, Chang C I. Kernel-based Constrained Energy Minimization[C]. SPIE, San Diego, California, 2008
- [39] Kwon H, Nasrabadi N M. Kernel Matched Subspace Detectors for Hyperspectral Target Detection [J]. *IEEE Trans. Pattern Anal. Mach. Intell.*, 2006, 28(2): 178-194
- [40] Wang T, Du B, Zhang L. A Kernel-Based Target-constrained Interference-minimized Filter for Hyperspectral Sub-pixel Target Detection[J]. *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, 2013, 6(2): 626-637
- [41] Schölkopf B, Smola A G. Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond[M]. Cambridge: MIT Press, 2002
- [42] Chen Y, Nasrabadi N M, Tran T D. Simultaneous Joint Sparsity Model for Target Detection in Hyperspectral Imagery[J]. *IEEE Geosci Remote Sens Lett.*, 2011, 8(4): 676-680
- [43] Wright J, Yang A Y, Ganesh A, et al. Robust Face Recognition via Sparse Representation [J]. *IEEE Trans. Pattern Anal Mach Intell.*, 2008, 31 (2): 210-227
- [44] Zhang Y, Du B, Zhang L. A Sparse Representation Based Binary Hypothesis Model for Target Detection in Hyperspectral Images [J]. *IEEE Trans. Geosci. Remote Sens.*, 2014, 10. 1109/TGRS. 2014. 2337883
- [45] Du B, Zhang L. Target Detection Based on a Dynamic Subspace[J]. *Pattern Recognit.*, 2014, 47 (1): 344-358
- [46] Du B, Zhang L. A Discriminative Metric Learning Based Anomaly Detection Method [J]. *IEEE Trans. Geosci. Remote Sens.*, 2014, 52 (11): 6 844-6 857
- [47] Zhang L, Zhang L, Tao D, et al. Hyperspectral Remote Sensing Image Subpixel Target Detection Based on Supervised Metric Learning [J]. *IEEE Trans. Geosci. Remote Sens.*, 2014, 52(8): 4 955-4 965
- [48] Wang T, Du B, Zhang L. An Automatic Robust Iteratively Reweighted Unstructured Detector for Hyperspectral Imagery[J]. *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, 2014, 10. 1109/JSTARS. 2014. 2320281
- [49] Rubinstein R, Zibulevsky M, Elad M. Efficient Implementation of the K-SVD Algorithm using Batch Orthogonal Matching Pursuit[D]. Haifa: Israel Institute of Technology, 2008
- [50] Manolakis D, Lockwood R, Cooley T, et al. Is There a Best Hyperspectral Detection Algorithm [C]. SPIE, Orlando, FL, 2009

(下转第 1400 页)

parison and analysis of the three classical gross error detection methods; data snooping, robust estimation (iteration method with variable weights) and random sample consensus (RANSAC). First, the steps of the three methods are described in detail. Next, gross error detection experiments using the three methods conducted with different gross error rates, i. e. 10%, 20%, 30% and 60%, respectively are reported. These experimental results show that RANSAC is more robust and less sensitive to the gross error rate than data snooping and robust estimation and therefore the most appropriate method for gross error detection in automatic geometric correction.

Key words: optical remote sensing; automatic geometric correction; RANSAC; data-snooping; robust estimation

First author: WANG Mi, PhD, professor, specializes in the theories and methods of remote sensing process. E-mail: wangmi@whu.edu.cn

Corresponding author: CHANG Xueli, PhD candidate. E-mail: 303505145@qq.com

Foundation support: The National Key Research and Development Program of China (973 Program), Nos. 2014CB744201, 2012CB719902; the National High Technology Research and Development Program of China(863 Program), No. 2011AA120203; the Program for New Century Excellent Talents in University; the Foundation for the Author of National Excellent Doctoral Dissertation of PR China (FANEDD), No. 201249; the Program for Changjiang Scholars and Innovative Research Team in University, No. IRT1278; the National Natural Science Foundation of China, No. 41371430.

+++++
(上接第 1394 页)

Advance and Future Challenges in Hyperspectral Target Detection

ZHANG Liangpei¹

1 State Key Laboratory of Information Engineering in Surveying, Mapping, and Remote Sensing,
Wuhan University, Wuhan 430079, China

Abstract: In this review, recent developments and future challenges in hyperspectral target detection are considered in relation to the two main approaches. The signal detection framework induced methods such as the structured backgrounds detector constrained energy minimization (CEM) and the unstructured backgrounds detector adaptive cosine/coherent estimation (ACE) are the classical methods of hyperspectral target detection, while advanced statistical pattern recognition and machine learning based approaches such as the kernel method and the sparse representation related algorithms are becoming the frontier topic in this area. The core concepts of these methods as well as their advantages and disadvantages are overviewed, and the future prospects of hyperspectral target detection are outlined.

Key words: hyperspectral image processing; target detection; signal detection; machine learning

First author: ZHANG Liangpei, professor, specializes in hyperspectral remote sensing, high resolution remote sensing and remote sensing application. E-mail: zlp62@whu.edu.cn

Foundation support: The National Natural Science Foundation of China, No. 41431175.